

Počítačové videnie a spracovanie obrazu

Zadanie 4 - 3D Gaussian splatting

Tadeáš Kapina a Radovan Janíček

11. mája 2026

Obsah

1	Spustenie na referenčnom datasete	3
1.1	Rozbehnutie projektu	3
1.2	Príprava dát	3
1.3	Rekonštrukcia scény pomocou COLMAP	4
1.3.1	Undistort snímky	7
1.4	Trénovanie 3D Gaussian splatting modelu	7
1.4.1	Vyhodnotenie PSNR	7
1.5	Vizualizácia výsledkov	8
2	Snímanie scény	8
3	Porovnanie výsledkov	9
3.1	Grafické porovnanie	10
4	Záver	10

1 Spustenie na referenčnom datasete

Začali sme spustením algoritmu na testovacom datasete, ktorý nám bol poskytnutý v zadaní využili sme dataset truck.

1.1 Rozbehnutie projektu

Ako prvý krok po nainštalovaní WSL, Dockeru a nvidia-container-toolkit sme vošli do naklonovaného repozitáru a zmenili sme .env súbor na cestu k našim dátam:

```
DATA_PATH=/mnt/c/dev/PVSO-gaussian-splatting-assignment/data
OUTPUT_PATH=/mnt/c/dev/PVSO-gaussian-splatting-assignment/output
```

Následne sme spustili

```
docker compose build
```

na vytvorenie docker kontajneru a potom sme čakali.

Po vytvorení kontajneru sme spustili príkaz ./run.sh, kde sme ďalej pokračovali v príprave a tréňovaní dát.

1.2 Príprava dát

Použili sme dataset truck zo stránky <https://www.tanksandtemples.org/download/>. Snímky sme presunuli do priečinku, ktorý sme nastavili ako data priečinkov v docker kontajneri.

V docker kontajneri sme snímky našli v priečinku /workspace/data/moja_scena/input.

Pre overview dát sme spustili príkaz

```
ls /workspace/data/moja_scena/input
```

```
root@docker-desktop:/opt/gaussian-splatting/data/moja_scena/input# ls
000001.jpg 000027.jpg 000053.jpg 000079.jpg 000105.jpg 000131.jpg 000157.jpg 000183.jpg 000209.jpg 000235.jpg
000002.jpg 000028.jpg 000054.jpg 000080.jpg 000106.jpg 000132.jpg 000158.jpg 000184.jpg 000210.jpg 000236.jpg
000003.jpg 000029.jpg 000055.jpg 000081.jpg 000107.jpg 000133.jpg 000159.jpg 000185.jpg 000211.jpg 000237.jpg
000004.jpg 000030.jpg 000056.jpg 000082.jpg 000108.jpg 000134.jpg 000160.jpg 000186.jpg 000212.jpg 000238.jpg
000005.jpg 000031.jpg 000057.jpg 000083.jpg 000109.jpg 000135.jpg 000161.jpg 000187.jpg 000213.jpg 000239.jpg
000006.jpg 000032.jpg 000058.jpg 000084.jpg 000110.jpg 000136.jpg 000162.jpg 000188.jpg 000214.jpg 000240.jpg
000007.jpg 000033.jpg 000059.jpg 000085.jpg 000111.jpg 000137.jpg 000163.jpg 000189.jpg 000215.jpg 000241.jpg
000008.jpg 000034.jpg 000060.jpg 000086.jpg 000112.jpg 000138.jpg 000164.jpg 000190.jpg 000216.jpg 000242.jpg
000009.jpg 000035.jpg 000061.jpg 000087.jpg 000113.jpg 000139.jpg 000165.jpg 000191.jpg 000217.jpg 000243.jpg
000010.jpg 000036.jpg 000062.jpg 000088.jpg 000114.jpg 000140.jpg 000166.jpg 000192.jpg 000218.jpg 000244.jpg
000011.jpg 000037.jpg 000063.jpg 000089.jpg 000115.jpg 000141.jpg 000167.jpg 000193.jpg 000219.jpg 000245.jpg
000012.jpg 000038.jpg 000064.jpg 000090.jpg 000116.jpg 000142.jpg 000168.jpg 000194.jpg 000220.jpg 000246.jpg
000013.jpg 000039.jpg 000065.jpg 000091.jpg 000117.jpg 000143.jpg 000169.jpg 000195.jpg 000221.jpg 000247.jpg
000014.jpg 000040.jpg 000066.jpg 000092.jpg 000118.jpg 000144.jpg 000170.jpg 000196.jpg 000222.jpg 000248.jpg
000015.jpg 000041.jpg 000067.jpg 000093.jpg 000119.jpg 000145.jpg 000171.jpg 000197.jpg 000223.jpg 000249.jpg
000016.jpg 000042.jpg 000068.jpg 000094.jpg 000120.jpg 000146.jpg 000172.jpg 000198.jpg 000224.jpg 000250.jpg
000017.jpg 000043.jpg 000069.jpg 000095.jpg 000121.jpg 000147.jpg 000173.jpg 000199.jpg 000225.jpg 000251.jpg
000018.jpg 000044.jpg 000070.jpg 000096.jpg 000122.jpg 000148.jpg 000174.jpg 000200.jpg 000226.jpg
000019.jpg 000045.jpg 000071.jpg 000097.jpg 000123.jpg 000149.jpg 000175.jpg 000201.jpg 000227.jpg
000020.jpg 000046.jpg 000072.jpg 000098.jpg 000124.jpg 000150.jpg 000176.jpg 000202.jpg 000228.jpg
000021.jpg 000047.jpg 000073.jpg 000099.jpg 000125.jpg 000151.jpg 000177.jpg 000203.jpg 000229.jpg
000022.jpg 000048.jpg 000074.jpg 000100.jpg 000126.jpg 000152.jpg 000178.jpg 000204.jpg 000230.jpg
000023.jpg 000049.jpg 000075.jpg 000101.jpg 000127.jpg 000153.jpg 000179.jpg 000205.jpg 000231.jpg
000024.jpg 000050.jpg 000076.jpg 000102.jpg 000128.jpg 000154.jpg 000180.jpg 000206.jpg 000232.jpg
000025.jpg 000051.jpg 000077.jpg 000103.jpg 000129.jpg 000155.jpg 000181.jpg 000207.jpg 000233.jpg
000026.jpg 000052.jpg 000078.jpg 000104.jpg 000130.jpg 000156.jpg 000182.jpg 000208.jpg 000234.jpg
root@docker-desktop:/opt/gaussian-splatting/data/moja_scena/input#
```

Obr. 1: Zoznam snímok v datasete truck

1.3 Rekonštrukcia scény pomocou COLMAP


Pred vytvorením COLMAP projektu som vytvoril priečinok `sparse/`, do ktorého sa ukládala databáza COLMAP:

```
mkdir -p /workspace/data/moja_scena/sparse
```

Následne sme spustili COLMAP GUI pomocou príkazu:

```
colmap gui
```

Najskôr sme začali cez `File -> New Project` vytvárať nový projekt, kde sme nastavili cestu k nášmu datasetu a zároveň sme vytvorili databázu v priečinku `sparse`:




Obr. 2: Vytvorenie projektu v COLMAP

Hodnoty ktoré sme nastavili:

```
Database /workspace/data/moja_scena/sparse/database.db  
Images   /workspace/data/moja_scena/input
```

Pokračovali sme `Processing -> Feature extraction`, kde sme nastavili hodnoty:




Nasledovalo Processing -> Feature matching, kde sme použili Exhaustive matching, ktorý porovnáva všetky snímky navzájom:



Obr. 4: Feature matching v COLMAP

Prácu s COLMAP sme ukončili spustením Reconstruction -> Start reconstruction, COLMAP vypočítal pozície kamier a vytvoril sparse point cloud.

V 3D okne sa postupne zobrazili kamery a body rekonštruovanej scény.



Obr. 5: Rekonštrukcia scény v COLMAP

Týmto sme dokončili COLMAP rekonštrukciu scény. Následne sme exportovali výsledky do priečinku `/workspace/data/moja_scena/distorted/sparse/0`, kde vznikli súbory `cameras.bin`, `images.bin` a `points3D.bin`, ktoré obsahujú informácie o kamerách, snímkach a 3D bodoch rekonštrukcie. V tomto priečinku ich očakáva `convert.py` na undisort snímok.

1.3.1 Undistort snímky

Po exportovaní výsledkov z COLMAP sme spustili príkaz:

```
python3 convert.py -s data/moja_scena --skip_matching
```

Takto sme pripravili dáta na tréovanie 3D Gaussian splatting modelu.

1.4 Tréovanie 3D Gaussian splatting modelu

Tréning 3D Gaussian Splatting modelu som spustil príkazom:

```
python3 train.py -s data/moja_scena --data_device cpu --resolution 4
--test_iterations 7000 30000 --save_iterations 7000 30000
```

1.4.1 Vyhodnotenie PSNR

Iterácia	PSNR [dB]
7 000	24.8915
30 000	27.5564

Tabuľka 1: PSNR hodnoty v rôznych iteráciách

```
root@docker-desktop:/opt/gaussian-splatting# python3 train.py -s data/moja_scena --data_device cpu --resolution 4 --test_iterations 7000 30000 --save_iterations 7000 30000
Optimizing
Output folder: ./output/9238c190-d [10/05 16:16:09]
Tensorboard not available: not logging progress [10/05 16:16:09]
Reading camera 251/251 [10/05 16:16:11]
Loading Training Cameras [10/05 16:16:11]
Loading Test Cameras [10/05 16:16:32]
Number of points at initialisation : 139952 [10/05 16:16:32]
Training progress: 19% [ ] | 5760/30000 [05:44<29:13, 13.83it/s, Loss=0.0565134, Depth Loss=0.0000000]
Training progress: 23% [ ] | 7000/30000 [07:29<33:14, 11.53it/s, Loss=0.0559216, Depth Loss=0.0000000]
[ITER 7000] Evaluating train: L1 0.0335642509162426 PSNR 24.891525650024416 [10/05 16:24:01]

[ITER 7000] Saving Gaussians [10/05 16:24:01]
Training progress: 100% [ ] | 30000/30000 [42:21<00:00, 11.80it/s, Loss=0.0380221, Depth Loss=0.0000000]

[ITER 30000] Evaluating train: L1 0.022755709290504456 PSNR 27.55639572143555 [10/05 16:58:54]

[ITER 30000] Saving Gaussians [10/05 16:58:54]

Training complete. [10/05 16:59:24]
```

Obr. 6: PSNR hodnoty počas trénovania modelu


1.5 Vizualizácia výsledkov

Pre vizuálne vyhodnotenie výsledkov sme použili príkaz:

```
SIBR_gaussianViewer_app -m output/9238c190-d
```

Kde 9238c190-d je názov priečinku, ktorý vznikol počas tréovania modelu a obsahuje výsledky tréovania.

V novom okne sa nám zobrazila rekonštruovaná scéna, ktorú sme mohli otáčať a pozeráť z rôznych uhlov.



Obr. 7: Vizualizácia výsledkov tréningu 3D Gaussian splatting modelu

2 Snímanie scény

Scéna bola nasnímaná priemyselnou kamerou Ximea v učebni D618. Snímali sme jednoduchú rubikovu kocku, ktorá má dobré parametre na takúto rekonštrukciu.

Snímanie bolo spravené cez python skript, ktorý snímал niekoľkokrát za sekundu a ukladalo snímky do súboru. Snímky boli robené postupne z rôznych uhlov, snažili sme sa pokryť čo najviac uhlov, aby sme získali čo najkompletnejší pohľad na scénu. Zároveň


sme sa snažili, aby snímky boli robené s malými rozdielmi v pozícii kamery, aby colmap vedel čo najlepšie spojiť rozličné snímky do jednej rekonštrukcie.

Dokopy bolo spravených 300 snímov v rozlíšení 1109x925 pixelov.

3 Porovnanie výsledkov

Pri vytváraní rekonštrukcie vlastnej scény sme použili rovnaký postup ako pri testovacom datasete. Po 30000 iteráciách sme dosiahli výsledky:

Náš finálny COLMAP model:



Obr. 8: Rekonštrukcia scény pomocou COLMAP

Po dokončení trénovania gaussian splatting modelu sme dostali:

```
root@d618-B550M-DS3H: /opt/gaussian-splatting
root@d618-B550M-DS3H:/opt/gaussian-splatting# python3 train.py -s data --data_de
vice cpu --iterations 30000
optimizing
output folder: ./output/6d57fa20-1 [11/05 13:56:10]
tensorboard not available: not logging progress [11/05 13:56:10]
reading camera 291/291 [11/05 13:56:10]
loading Training Cameras [11/05 13:56:10]
loading Test Cameras [11/05 13:56:18]
number of points at initialisation : 6793 [11/05 13:56:18]
training progress: 23%| | 7000/30000 [12:22<54:33, 7.03it/s, Loss=0.0464696, D
ITER 7000] Evaluating train: L1 0.030042972788214686 PSNR 26.522711181640627 [1
/05 14:08:41]

ITER 7000] Saving Gaussians [11/05 14:08:41]
training progress: 100%|█| 30000/30000 [1:07:49<00:00, 7.37it/s, Loss=0.0288812

ITER 30000] Evaluating train: L1 0.019371012412011626 PSNR 30.603572845458984 [
11/05 15:04:07]

ITER 30000] Saving Gaussians [11/05 15:04:07]

training complete. [11/05 15:04:09]
root@d618-B550M-DS3H:/opt/gaussian-splatting#
```

Obr. 9: Výsledky rekonštrukcie scény pomocou 3D Gaussian splatting modelu


Porovnanie PSNR hodnôt v rôznych iteráciách pre testovací dataset a našu scénu:

Dáta	Iterácia	PSNR [dB]
Testovací dataset	7 000	24.8915
Testovací dataset	30 000	27.5564
Naša scéna	7 000	26.5227
Naša scéna	30 000	30.6036

Tabuľka 2: PSNR hodnoty v rôznych iteráciách

3.1 Grafické porovnanie

Náš finálny model v grafickom zobrazení:



Obr. 10: Finálny model - pohľady zo strany

4 Záver

Podarilo sa nám úspešne zrekonštruovať rubikovu kocku, ktorú sme chceli nasnímať. PSNR hodnoty sme dosiahli lepšie ako na referenčnom datasete, čo môže byť spôsobené tým, že sme mali lepšie pokrytie snímok a menšiu scénu, ktorú sme rekonštruovali.

Pozadie scény nie je dobrým stave, za čo môže pravdepodobne sústredenie väčšiny snímok na samotnú kocku a rozostrenie na väčšie vzdialenosti.

Takisto sme nesníмали snímky dostatočne plynulo a museli sme využiť Exhaustive matching, ktorý porovnáva všetky snímky navzájom, namiesto Sequential matching, ktorý porovnáva len snímky, ktoré sú blízko seba.

Počas skúšania nasnímania scény sme sa stretli s viacerými problémami, keď sme sa prvý krát pokúšali oskenovať priesvitnú plastovú fľašku, ktorá sa nám nedarila zrekonštruovať, pravdepodobne kvôli tomu, že je priesvitná a má lesklý povrch, čo spôsobovalo problémy pri detekcii a porovnávaní snímok v COLMAPE.

Podobne sa nám nepodarilo zrekonštruovať model drona, ktorý sme snímali za nepriaznivých svetelných podmienok, kde snímky boli veľmi presvetlené a v rekonštrukcii COLMAP a 3D Gaussian splatting splývali do neidentifikovateľného objektu.